

**Perbandingan Hybrid Resampling pada Penanganan Imbalanced
Loan Default Menggunakan Random Forest, LightGBM, dan
Logistic Regression**



Disusun untuk memenuhi Tugas Akhir
Mata Kuliah IF-32025 / Penambangan Data
Semester Genap

Dosen Pengampu : Meida Cahyo Untoro, S.Kom., M.Kom.

Nama Anggota :

Rafael Abimayu Ratmoko	(123140134)
Aprililianti	(123140041)
Ola Anggela Rosita	(123140042)
Kristof Tsunami Ginting	(123140117)
Prima Agusta Sembiring	(123140119)
Ali Akbar	(123140162)
I Gede Krisna Yoga Saputra	(123140163)

**PROGRAM STUDI TEKNIK INFORMATIKA
FAKULTAS TEKNOLOGI INDUSTRI
INSTITUT TEKNOLOGI SUMATERA
2026**

BAB 1

Pendahuluan

1.1 Latar Belakang

Perkembangan teknologi informasi mendorong pemanfaatan data skala besar dalam pengambilan keputusan yang lebih akurat. Dalam *machine learning*, kualitas data menjadi faktor krusial yang menentukan performa model, sehingga tahap *preprocessing* tidak dapat diabaikan. Salah satu tantangan utama adalah *imbalance data*, yaitu ketidakseimbangan distribusi kelas yang menyebabkan bias terhadap kelas mayoritas serta menurunkan kemampuan model dalam mendeteksi kelas minoritas. Permasalahan ini banyak terjadi pada domain keuangan, seperti prediksi persetujuan pinjaman, di mana dominasi kelas *approved* dapat menghasilkan akurasi tinggi namun tidak merefleksikan kinerja model secara representatif.

Berbagai pendekatan seperti *oversampling* dan *undersampling* telah digunakan, namun masih memiliki keterbatasan. Pendekatan *hybrid* seperti SMOTE-ENN terbukti lebih efektif dalam meningkatkan performa model (Adewumi et al., 2025, 1,11). Oleh karena itu, penelitian ini berfokus pada perbandingan metode *hybrid resampling* (SMOTE-Tomek, SMOTE-ENN, dan Borderline-SMOTE) untuk meningkatkan kinerja klasifikasi pada dataset *Loan Default* yang tidak seimbang.

1.2 Rumusan Masalah

Penelitian ini berusaha menjawab tiga pertanyaan utama:

1. Bagaimana perbandingan efektivitas metode hybrid resampling (SMOTE-ENN, SMOTE-Tomek, dan Borderline-SMOTE) dalam meningkatkan performa klasifikasi pada data tidak seimbang, dibandingkan dengan skenario tanpa resampling?
2. Di antara tiga algoritma klasifikasi (Random Forest, LightGBM, dan Logistic Regression), algoritma mana yang menghasilkan

performa terbaik ketika dikombinasikan dengan metode hybrid resampling?

3. Kombinasi metode resampling dan algoritma klasifikasi mana yang memberikan nilai F1-Score dan G-Mean tertinggi pada data uji asli?

1.3 Tujuan Penelitian

Penelitian ini memiliki tiga tujuan utama:

1. Mengimplementasikan dan membandingkan dua metode hybrid resampling (SMOTE-ENN, SMOTE-Tomek) dan oversampling satu pure Borderline-SMOTE) pada data latih, serta mengevaluasi dampaknya terhadap performa klasifikasi.
2. Membandingkan kinerja tiga algoritma klasifikasi (Random Forest, LightGBM, dan Logistic Regression) pada dataset yang telah diseimbangkan dengan masing-masing metode hybrid resampling dan oversampling.
3. Mengidentifikasi kombinasi terbaik antara metode resampling dan algoritma klasifikasi berdasarkan metrik Confusion Matrix, Precision, Recall, F1-Score, dan PR-AUC dan ROC-AUC yang diukur langsung pada data uji.

1.4 Batasan Masalah

Penelitian ini menetapkan batasan-batasan sebagai berikut:

- 1) Dataset:
 1. Menggunakan Loan Approval Classification Data dari repository Kaggle (oleh kontributor *taweilo*).
 2. Dataset terdiri dari 255.347 baris dan 18 kolom fitur
 3. Variabel target adalah Default, di mana nilai 1. merepresentasikan nasabah gagal bayar dan 0 merepresentasikan nasabah yang memenuhi kewajiban kreditnya.
- 2) Metode Resampling:

1. Fokus penelitian dibatasi pada perbandingan teknik hybrid (SMOTE-ENN dan SMOTE-Tomek) serta satu teknik oversampling (Borderline-SMOTE).
 2. Menggunakan skenario tanpa resampling sebagai baseline (pembanding utama).
- 3) Pembagian Data:
1. Resampling hanya diterapkan pada data latih (80% dari total data).
 2. Data uji (20%) dibiarkan dalam kondisi asli (tidak diseimbangkan) untuk mensimulasikan evaluasi pada data dunia nyata.
- 4) Algoritma Klasifikasi:
1. Dibatasi pada Random Forest, LightGBM, dan Logistic Regression.
 2. Eksperimen dilakukan menggunakan konfigurasi parameter standar (default) untuk menjaga konsistensi perbandingan antar skenario resampling.

1.5 Research Gap

Penelitian sebelumnya telah banyak memanfaatkan metode seperti SMOTE untuk menangani *imbalance data* serta algoritma machine learning seperti Random Forest untuk prediksi, sebagaimana ditunjukkan oleh Sirait et al. (2023) dan Karabacak & Yaslan (2023). Selain itu, studi perbandingan antar teknik juga telah dilakukan, misalnya oleh Masruriyah et al. (2024). Namun, belum terdapat penelitian yang secara langsung membandingkan performa teknik *hybrid resampling* seperti SMOTE-ENN dan SMOTE-Tomek, serta teknik *oversampling* seperti Borderline-SMOTE terhadap algoritma machine learning seperti Random Forest, LightGBM, dan Logistic Regression. Oleh karena itu, novelty penelitian ini terletak pada perbandingan komprehensif metode penanganan *imbalance data* terhadap berbagai model machine learning.

BAB 2

Tinjauan Pustaka

2.1 Class Imbalanced

Ketidakseimbangan kelas (*class imbalance*) adalah kondisi timpangnya distribusi data yang didominasi oleh kelas mayoritas, yang diukur menggunakan *Imbalanced Ratio* (IR). Masalah yang sering terjadi di bidang kesehatan, keuangan, dan teknik ini dapat menyebabkan model menjadi bias dan gagal mengenali pola kelas minoritas. Untuk mengatasinya, terdapat tiga kategori pendekatan utama: teknik tingkat data (memodifikasi distribusi data sebelum *training*, seperti *oversampling*, *undersampling*, atau sintesis data), teknik tingkat algoritma (menyesuaikan sensitivitas model), dan metode hibrida yang menggabungkan kedua pendekatan tersebut untuk hasil yang lebih optimal (ALTALHAN et al., 2025, 1-2).

2.2 Teknik Hybrid Resampling

2.2.1 SMOTE-ENN (SMOTE + Edited Nearest Neighbours)

SMOTE-ENN merupakan metode hybrid resampling yang menggabungkan SMOTE sebagai tahap oversampling dan ENN sebagai tahap data cleaning secara sekuensial. Pada tahap pertama, SMOTE membangkitkan sampel sintetis untuk kelas minoritas melalui interpolasi linear dengan k-nearest neighbor-nya, kemudian ENN menghapus setiap sampel yang salah diklasifikasikan oleh mayoritas k-neighbor terdekatnya. Karakteristik cleaning dua arah ini membersihkan sampel mayoritas yang ambigu sekaligus sampel minoritas sintetis yang noisy, sehingga menghasilkan dataset yang lebih bersih (Adewumi et al., 2025, 71276)(Akinjole et al., 2024, 1). Pendekatan ini relevan untuk dataset keuangan dengan tingkat overlap antar kelas tinggi, meskipun pengurangan ukuran data akibat agresivitas ENN perlu dipertimbangkan (Mukherjee et al., 2025, 4).

2.2.2 SMOTE-Tomek

SMOTE-Tomek adalah metode yang digunakan untuk mengatasi masalah ketidakseimbangan kelas (*class imbalance*) dengan menggabungkan teknik *oversampling* dan *undersampling*. Metode ini merupakan kombinasi antara SMOTE (*Synthetic Minority Oversampling Technique*) yang berfungsi menambahkan data sintetis pada kelas minoritas, dan Tomek Link yang digunakan untuk menghapus pasangan data dari kelas yang berbeda yang saling berdekatan atau tumpang tindih. Dengan pendekatan ini, SMOTE-Tomek tidak hanya menyeimbangkan jumlah data antar kelas, tetapi juga memperbaiki kualitas batas antar kelas dengan mengurangi noise. Hal ini membuat model klasifikasi dapat belajar dengan lebih baik, terutama dalam membedakan kelas minoritas, sehingga meningkatkan performa secara keseluruhan (Khleel, 2022, 9).

2.3 Teknik Oversampling

2.3.1 Borderline-SMOTE

Borderline-SMOTE, yaitu pengembangan dari SMOTE yang berfokus pada area batas keputusan (*decision boundary*). Metode ini menghasilkan data sintetis di sekitar batas antar kelas dan hanya melakukan *oversampling* pada sebagian kecil sampel yang berada di area tersebut. Dalam prosesnya, SMOTE memilih sampel minoritas secara acak, sedangkan *Borderline SMOTE* secara selektif memilih sampel minoritas yang berada dekat dengan kelas mayoritas, yaitu ketika sebagian besar tetangga terdekatnya berasal dari kelas mayoritas. Dengan demikian, metode ini difokuskan pada sampel yang berada di area pinggiran kelas minoritas. Pendekatan ini mampu memperjelas batas keputusan sehingga meningkatkan performa klasifikasi, meskipun kompleksitasnya meningkat. Selain itu, *Borderline SMOTE* juga

dapat mengurangi risiko *overfitting* karena sampel sintetis dihasilkan di area yang relevan, serta membantu meminimalkan noise dengan menghasilkan data pada lokasi yang lebih terarah. Fleksibilitasnya dalam dikombinasikan dengan berbagai algoritma machine learning juga menjadikan metode ini efektif dalam meningkatkan kinerja model secara keseluruhan. (Sun et al., 2022, 3)

2.4 Algoritma Klasifikasi

2.4.1 Random Forest

Random Forest diposisikan sebagai algoritma klasifikasi utama dalam penelitian ini. Random Forest merupakan model *ensemble learning* berbasis *bagging* yang membangun sejumlah besar pohon keputusan independen dari *bootstrap sample* data latih dan menggabungkan hasil prediksinya melalui mekanisme *majority voting* (Deshpande & Ragha, 2025, 5). Metode ini dikenal stabil menghadapi ketidakseimbangan kelas tanpa penyesuaian hiperparameter kompleks. Pada domain prediksi kelayakan pinjaman, Random Forest konsisten menunjukkan performa unggul. Pada evaluasi risiko kredit dengan data tidak seimbang, Random Forest juga terbukti mengungguli empat algoritma klasifikasi lainnya (Dong et al., 2024, 10-15). Dengan demikian, perbedaan performa antara skenario eksperimen dapat diatribusikan secara lebih jelas pada metode *resampling* yang diterapkan (Adewumi et al., 2025, 2-3).

2.4.2 LightGBM (Light Gradient Boosting Machine)

LightGBM adalah algoritma ensemble berbasis gradient boosting yang menerapkan pertumbuhan pohon leaf-wise serta inovasi Gradient-based One-Side Sampling (GOSS) dan Exclusive Feature Bundling (EFB) untuk efisiensi komputasi. Dalam konteks prediksi risiko kredit, kombinasi LightGBM dengan SMOTE-ENN

terbukti mampu mengidentifikasi nasabah potensial secara lebih akurat (Yu et al., 2024, 6-7). Pada domain keuangan digital, framework HBA-LGBM yang menggabungkan augmentasi data sintetis dan cost-sensitive learning berhasil mencapai performa tinggi dengan R^2 0,998 pada dataset LendingClub (Ying et al., 2025, 11). Selain itu, LightGBM juga diidentifikasi sebagai model paling optimal dalam sistem penilaian risiko kredit yang transparan, dengan akurasi 90,07% serta keseimbangan terbaik antara tingkat persetujuan dan risiko gagal bayar (Shreya & Pathak, 2025, 10).

2.4.3 Logistic Regression

Logistic regression adalah metode yang digunakan untuk melihat hubungan antara beberapa faktor dengan suatu hasil yang memiliki dua kemungkinan, misalnya ya atau tidak. Metode ini digunakan untuk memperkirakan kemungkinan terjadinya suatu kejadian berdasarkan nilai dari faktor-faktor yang mempengaruhinya. Hasil dari metode ini berupa nilai peluang antara 0 sampai 1, yang kemudian digunakan untuk menentukan kategori hasil tersebut. Perhitungan dalam metode ini melibatkan nilai dasar (konstanta) serta pengaruh dari masing-masing faktor yang digunakan (Baloch & Muhammad, 2021, 22474)

2.5 Metrik Evaluasi

Karena akurasi yang kurang memadai dalam merepresentasikan kinerja model pada kondisi data yang tidak seimbang, penelitian ini menggunakan metrik evaluasi yang berfokus pada kemampuan deteksi kelas minoritas. Confusion Matrix digunakan sebagai dasar untuk mengevaluasi kinerja klasifikasi, sementara Precision mengukur ketepatan prediksi positif dan Recall menilai kemampuan model dalam mengidentifikasi seluruh data positif. F1-Score digunakan untuk memberikan keseimbangan antara Precision dan Recall. ROC-AUC

mengukur kemampuan model membedakan antar kelas pada berbagai threshold, sedangkan PR-AUC lebih sensitif terhadap performa pada data tidak seimbang karena berfokus pada trade-off antara Precision dan Recall. Penggunaan metrik-metrik ini menghasilkan evaluasi yang lebih objektif dan representatif pada dataset yang tidak seimbang (Sharma et al., 2025,11-13).

BAB 3

Metodologi Penelitian

3.1 Alur Penelitian

Penelitian ini dilaksanakan melalui tujuh tahap yang terstruktur dan sistematis. Tahap pertama adalah pengumpulan dataset Loan Default Prediction dari repositori publik Kaggle, yang terdiri dari 255.347 baris dengan 17 fitur dan 1 variabel target (Default), termasuk variabel identitas nasabah (LoanID). Untuk efisiensi komputasi, diambil sampel 30.000 baris menggunakan stratified random sampling (`random_state=42`) guna mempertahankan proporsi kelas dan menjamin reproduktibilitas hasil.

Tahap kedua adalah eksplorasi dan preprocessing data, mencakup analisis distribusi kelas, pemeriksaan missing values dan duplikasi, serta encoding fitur kategorikal menggunakan ColumnTransformer yang diintegrasikan di dalam ImbPipeline. Fitur biner (HasMortgage, HasDependents, HasCoSigner) diproses menggunakan `OneHotEncoder(drop='if_binary')`, fitur multi-kategori (EmploymentType, MaritalStatus, LoanPurpose) menggunakan `OneHotEncoder(drop='first', handle_unknown='ignore')`, fitur ordinal (Education) menggunakan OrdinalEncoder dengan urutan hierarkis [High School, Bachelor's, Master's, PhD], serta fitur numerik dinormalisasi menggunakan StandardScaler. Seluruh tahap preprocessing ini hanya dipelajari dari data latih untuk menghindari data leakage.

Tahap ketiga adalah pembagian data menjadi data latih 80% (24.000 data) dan data uji 20% (6.000 data) menggunakan stratified split (`stratify=y`, `random_state=42`) untuk menjaga proporsi kelas pada kedua subset.

Tahap keempat adalah penerapan tiga metode resampling (SMOTE-ENN, SMOTE-Tomek, dan Borderline-SMOTE) beserta satu skenario baseline tanpa resampling, yang seluruhnya hanya diterapkan pada data latih melalui ImbPipeline. Data uji dibiarkan dalam kondisi aslinya untuk mensimulasikan evaluasi pada kondisi dunia nyata. Tahap kelima adalah pelatihan model menggunakan skema ImbPipeline dari pustaka imbalanced-learn, yang mengintegrasikan tiga tahap secara sekuensial: preprocessing

(ColumnTransformer), resampling (hanya pada data latih), dan klasifikasi. Proses ini menghasilkan 12 kombinasi eksperimen (4 skenario resampling $\times$ 3 algoritma: Random Forest, LightGBM, dan Logistic Regression).

Tahap keenam adalah Cross Validation menggunakan StratifiedKFold dengan 5 fold untuk mengevaluasi stabilitas performa tiap kombinasi model-metode secara lebih robust, dengan metrik scoring average_precision dan f1. Cross validation digunakan untuk menentukan kombinasi model dan metode resampling yang paling optimal sebagai kandidat untuk tahap tuning. Tahap ketujuh adalah Hyperparameter Tuning menggunakan RandomizedSearchCV pada kombinasi terbaik hasil cross validation, yaitu Logistic Regression + Borderline-SMOTE. Parameter yang diuji meliputi solver (liblinear, lbfgs), penalty (l1, l2), dan C (0.0001–10) dengan 50 iterasi pencarian dan scoring average_precision. Tahap terakhir adalah evaluasi model final menggunakan metrik F1-Score, Confusion Matrix, PR-AUC, Precision, Recall, dan ROC-AUC pada data uji asli.

3.2 Deskripsi Dataset

Dataset yang digunakan dalam penelitian ini adalah Loan Default Prediction Dataset yang merupakan dataset klasifikasi biner berskala cukup besar yang memuat 255.347 baris data dan 18 kolom yang berisi informasi tentang profil peminjaman, kondisi keuangan, karakteristik pinjaman serta riwayat kredit nasabah. Variabel target pada dataset ini adalah Default yang digunakan untuk menunjukkan apakah seorang nasabah mengalami gagal bayar pinjaman atau tidak sehingga dataset termasuk dalam permasalahan klasifikasi biner. Dataset ini memiliki kombinasi data numerik dan kategorikal serta digunakan untuk analisis *Exploratory Data Analysis* (EAD) dan pengembangan model *machine learning* dalam prediksi risiko kredit.

3.2.1 Pembagian Data (Train-Test Split)

Variabel target pada penelitian ini adalah Default dengan nilai biner: 0 (tidak default / pinjaman lancar) dan 1 (default /

pinjaman bermasalah). Distribusi kelas pada dataset menunjukkan ketidakseimbangan yang signifikan antara kelas mayoritas (0) dan kelas minoritas (1), sehingga penanganan khusus terhadap kondisi imbalanced menjadi salah satu fokus utama penelitian ini.

Data kemudian dibagi menggunakan Stratified Train-Test Split dengan rasio 80:20, menghasilkan 24.000 data latih dan 6.000 data uji. Penerapan parameter stratify=y bertujuan memastikan proporsi kelas minoritas terjaga secara konsisten pada kedua subset, sehingga proses latihan maupun evaluasi model tidak terdistorsi akibat distribusi kelas yang tidak representatif.

3.2.2 Deskripsi Fitur

Dataset ini terdiri dari beberapa fitur yang memuat informasi mengenai profil peminjam, kondisi keuangan, dan detail pinjaman. Setiap fitur digunakan sebagai variabel dalam proses analisis dan prediksi gagal bayar pinjaman. Berikut deskripsi masing-masing fitur dapat dilihat pada tabel dibawah ini :

No	Nama Fitur	Deskripsi
1	LoanID	ID unik untuk setiap data pinjaman
2	Age	Usia peminjam
3	Income	Pendapatan peminjam
4	LoanAmount	Jumlah pinjaman yang diajukan
5	CreditScore	Skor kredit peminjam
6	MonthsEmployed	Lama bekerja peminjam dalam bulan
7	NumCreditLines	Jumlah jalur kredit yang dimiliki
8	InterestRate	Suku bunga pinjaman
9	LoanTerm	Jangka waktu pinjaman

10	DTIRatio	Rasio utang terhadap pendapatan (<i>Debt to Income Ratio</i>)
11	Education	Tingkat pendidikan peminjam
12	EmploymentType	Jenis pekerjaan peminjam
13	MaritalStatus	Status pernikahan peminjam
14	HasMortgage	Status kepemilikan cicilan rumah
15	HasDependents	Status tanggungan keluarga
16	LoanPurpose	Tujuan pengajuan pinjaman
17	HasCoSigner	Status adanya penjamin pinjaman
18	Default	Status gagal bayar pinjaman (target)

Tabel 3.1 Deskripsi Fitur Dataset Loan Default Prediction

3.2.3 Kualitas Data

Pemeriksaan kualitas data dilakukan untuk memastikan dataset layak digunakan dalam proses pemodelan. Pemeriksaan mencakup identifikasi missing values, data duplikat, serta validasi rentang nilai pada fitur numerik berdasarkan konteks domain. Hasil pemeriksaan menunjukkan bahwa dataset tidak memiliki missing values maupun data duplikat, sehingga tidak diperlukan tahap imputasi ataupun penghapusan data. Selain itu, seluruh fitur numerik berada pada rentang nilai yang wajar dan konsisten dengan karakteristik data keuangan.

3.2.4 Preprocessing

Seluruh proses preprocessing diimplementasikan di dalam ImbPipeline menggunakan ColumnTransformer, sehingga transformasi hanya dipelajari dari data latih dan diterapkan ke data uji untuk menghindari data leakage. Proses ini memastikan bahwa seluruh encoder dan scaler tidak terekspos oleh informasi dari data uji pada saat fitting.

Preprocessing dibagi berdasarkan tipe kolom sebagai berikut:

- a. Fitur Biner (HasMortgage, HasDependents, HasCoSigner) diproses menggunakan `OneHotEncoder (drop='if_binary')`, yang menghasilkan satu kolom numerik (0 atau 1) per fitur tanpa redundansi kolom.
- b. Fitur Multi-Kategori (EmploymentType, MaritalStatus, LoanPurpose) diproses menggunakan `OneHotEncoder(drop='first', handle_unknown='ignore')`, yang menghasilkan kolom dummy dengan menghapus satu kategori sebagai referensi untuk menghindari multikolinearitas.
- c. Fitur Ordinal (Education) diproses menggunakan `OrdinalEncoder` dengan urutan hierarkis yang ditentukan secara eksplisit: [High School, Bachelor's, Master's, PhD], sehingga urutan tingkat pendidikan terjaga secara numerik dan bermakna.
- d. Fitur Numerik (Age, Income, LoanAmount, CreditScore, MonthsEmployed, NumCreditLines, InterestRate, LoanTerm, DTIRatio) dinormalisasi menggunakan `StandardScaler` agar seluruh fitur numerik berada pada skala yang seragam, yang khususnya penting untuk model Logistic Regression yang sensitif terhadap perbedaan skala fitur.

Seluruh transformer di atas dirangkai dalam satu `ColumnTransformer` dengan parameter `remainder='drop'`, yang berarti kolom yang tidak terdefinisi dalam salah satu transformer akan dibuang secara otomatis. `ColumnTransformer` ini kemudian menjadi tahap pertama dalam `ImbPipeline` sebelum resampling dan klasifikasi.

3.3 Prosedur Eksperimen

3.3.1 Pembagian Data (Train-Test Split)

Dataset sampel sebesar 30.000 baris dibagi menjadi dua subset menggunakan fungsi `train_test_split` dari pustaka `scikit-learn` dengan proporsi 80:20 dan `stratified split` (`stratify=y`, `random_state=42`).

Pembagian ini menghasilkan data latih sebanyak 24.000 sampel dan data uji sebanyak 6.000 sampel.

Distribusi kelas pada data latih adalah 21.234 sampel kelas 0 (tidak default) dan 2.766 sampel kelas 1 (default), dengan Imbalance Ratio (IR) sebesar 7,68 : 1. Pada data uji terdapat 5.309 sampel kelas 0 dan 691 sampel kelas 1, yang akan digunakan untuk evaluasi dalam kondisi distribusi asli (real-world) tanpa dilakukan resampling.

Penerapan parameter stratify=y bertujuan memastikan proporsi kelas minoritas terjaga secara konsisten pada kedua subset, sehingga proses pelatihan maupun evaluasi model tidak terdistorsi akibat distribusi kelas yang tidak representatif. Seluruh proses resampling hanya diterapkan pada data latih melalui ImbPipeline, sementara data uji dibiarkan dalam kondisi aslinya.

3.3.2 Metode Resampling

Penelitian ini menggunakan tiga metode resampling, yaitu SMOTE-ENN, SMOTE-Tomek, dan Borderline-SMOTE, untuk menangani ketidakseimbangan kelas pada dataset loan default. Seluruh metode resampling hanya diterapkan pada data latih (24.000 sampel), sedangkan data uji (6.000 sampel) dipertahankan dalam kondisi aslinya agar evaluasi model merepresentasikan distribusi data nyata. Implementasi resampling diintegrasikan ke dalam ImbPipeline, sehingga proses penyeimbangan kelas hanya dilakukan pada data latih selama proses pelatihan dan cross validation, sekaligus mencegah terjadinya data leakage.

Penelitian ini membandingkan empat skenario eksperimen, yaitu satu skenario baseline tanpa resampling serta tiga skenario dengan penerapan masing-masing metode resampling. Dengan demikian, pengaruh setiap teknik penanganan ketidakseimbangan kelas terhadap performa model dapat dianalisis secara sistematis.

3.3.3 Algoritma Klasifikasi

Tiga algoritma klasifikasi digunakan dalam eksperimen ini, yaitu Random Forest, LightGBM, dan Logistic Regression, untuk membandingkan performa model berbasis ensemble tree, gradient boosting, dan model linear pada prediksi loan default. Random Forest dikonfigurasi dengan $n_estimators=100$, $random_state=42$, dan $n_jobs=-1$ untuk memaksimalkan pemanfaatan seluruh inti prosesor selama proses pelatihan. LightGBM menggunakan $n_estimators=100$, $verbose=-1$, $random_state=42$, dan $n_jobs=-1$, dengan parameter $verbose=-1$ untuk menekan output log selama proses training. Logistic Regression dikonfigurasi dengan $max_iter=300$, $random_state=42$, dan $n_jobs=-1$, di mana peningkatan max_iter dilakukan untuk memastikan proses optimasi mencapai konvergensi pada data yang telah distandardisasi.

3.3.4 Metrik Evaluasi

Mengingat akurasi global tidak representatif pada kondisi data tidak seimbang, penelitian ini menggunakan beberapa metrik evaluasi yang berfokus pada kemampuan model dalam mengenali kelas minoritas (default). Metrik yang digunakan meliputi Precision, Recall, F1-Score, ROC-AUC, PR-AUC, serta Confusion Matrix untuk memberikan gambaran distribusi prediksi secara menyeluruh.

Precision mengukur proporsi prediksi positif yang benar-benar termasuk kelas positif, dihitung sebagai $TP/(TP+FP)$. Recall (Sensitivity) mengukur kemampuan model dalam mengidentifikasi seluruh sampel positif, dihitung sebagai $TP/(TP+FN)$. F1-Score merupakan rata-rata harmonik antara Precision dan Recall yang memberikan keseimbangan antara keduanya, dihitung sebagai $2 \times (Precision \times Recall) / (Precision + Recall)$. Pada kondisi data tidak seimbang, F1-Score lebih diutamakan dibanding akurasi karena tidak terpengaruh oleh dominasi kelas mayoritas.

Selain itu, ROC-AUC (Receiver Operating Characteristic - Area Under Curve) digunakan untuk mengukur kemampuan model dalam membedakan antara kelas positif dan negatif pada berbagai threshold.

Namun pada kondisi data yang sangat tidak seimbang, ROC-AUC cenderung memberikan gambaran yang terlalu optimistis karena dipengaruhi oleh besarnya proporsi kelas negatif. Oleh karena itu, PR-AUC (Precision-Recall Area Under Curve) digunakan sebagai metrik utama pemilihan model, karena berfokus pada trade-off antara Precision dan Recall khusus pada kelas minoritas dan lebih sensitif terhadap performa deteksi kelas default yang jumlahnya jauh lebih sedikit. Dalam penelitian ini, PR-AUC juga digunakan sebagai scoring utama pada proses Cross Validation dan Hyperparameter Tuning.

Confusion Matrix disertakan untuk memberikan gambaran lengkap mengenai distribusi hasil prediksi model, termasuk jumlah True Positive (TP), False Positive (FP), True Negative (TN), dan False Negative (FN). Dari Confusion Matrix inilah nilai Precision, Recall, dan F1-Score diturunkan secara langsung.

BAB 4

Hasil dan Pembahasan

4.1 Eksplorasi Data (EDA)


4.1.1 Gambaran Umum Dataset

Dataset yang digunakan adalah Loan Default Prediction yang diperoleh dari repositori publik Kaggle. Dataset asli terdiri dari 255.347 baris dan 18 kolom, yang mencakup 16 fitur prediktor, 1 variabel target (Default), dan 1 kolom identitas (LoanID). Kolom LoanID dihapus karena tidak memiliki relevansi prediktif dalam proses pemodelan. Setelah dilakukan stratified random sampling sebanyak 30.000 sampel, dataset yang digunakan terdiri dari 30.000 baris, 16 fitur prediktor, dan 1 variabel target.

Analisis distribusi variabel target menunjukkan adanya ketidakseimbangan kelas yang signifikan. Dari total 30.000 sampel, kelas non-default (0) mendominasi dengan proporsi sekitar 88,38%, sedangkan kelas default (1) hanya sebesar 11,62%, menghasilkan rasio ketidakseimbangan sekitar 7,6:1. Kondisi ini berpotensi menyebabkan model klasifikasi cenderung bias terhadap kelas mayoritas, sehingga diperlukan penerapan teknik resampling untuk meningkatkan kemampuan model dalam mengenali kelas minoritas.


Berdasarkan statistik deskriptif, fitur Income memiliki rentang nilai yang luas, yaitu dari 15.000 hingga 149.993, dengan standar deviasi sebesar 38.989, yang menunjukkan variasi pendapatan antar pemohon yang cukup tinggi. Fitur CreditScore memiliki nilai rata-rata sebesar 575,22 dengan median 575, yang menunjukkan distribusi nilai yang relatif seimbang di sekitar pusat data. Sementara itu, fitur InterestRate menunjukkan variasi yang cukup besar antar pemohon, dengan rentang nilai 2 hingga 25 dan standar deviasi sebesar 6,64. Selain itu, seluruh variabel memiliki jumlah observasi lengkap sebanyak 30.000 data, sehingga tidak ditemukan missing values dan tahap imputasi tidak diperlukan.

4.1.2 Distribusi Kelas Target



Gambar 4.1 Distribusi Target Variable (Default)


Gambar 4.1 menampilkan distribusi variabel target Default menggunakan dua jenis chart: bar chart dan pie chart. Dari 30.000 data, sebanyak 26.543 nasabah (88,5%) tidak gagal bayar (Default = 0), sedangkan 3.457 nasabah (11,5%) mengalami gagal bayar (Default = 1).



Gambar 4.2 Distribusi Fitur Kategorikal vs Target

Grafik 4.2 membandingkan rata-rata tingkat gagal bayar (Default) di setiap kategori dari empat fitur kategorikal. Setiap bar menunjukkan proporsi default pada kelompok tersebut beserta confidence interval (error bar hitam).


- Education: Lulusan High School memiliki tingkat default tertinggi (~13,3%), sedangkan PhD terendah (~9,8%)
- EmploymentType: Pengangguran (Unemployed) paling berisiko (~13,1%), sementara Full-time paling aman (~9,9%)
- MaritalStatus: Status Divorced sedikit lebih berisiko (~12,4%) dibanding Married (~10,1%)
- HasCoSigner: Nasabah tanpa co-signer lebih berisiko (~12,6%) vs yang punya (~10,4%)



Gambar 4.3 Histogram Distribusi Fitur Numerik vs Target

Overlay histogram dari enam fitur numerik yang membandingkan distribusi kelompok Default=0 (biru) dan Default=1 (oranye) disertai kurva KDE (Kernel Density Estimation). Fitur yang dianalisis: Age, MonthsEmployed, Income, LoanAmount, CreditScore, dan InterestRate.

- Age: Nasabah yang default cenderung lebih muda (puncak di sekitar usia 18–25 tahun).
- Income: Nasabah default memiliki distribusi income yang lebih rendah dan condong ke kiri.
- LoanAmount: Nasabah default cenderung mengambil pinjaman lebih besar.
- InterestRate: Distribusi default condong ke suku bunga lebih tinggi.
- CreditScore & MonthsEmployed: Distribusi relatif serupa antar kedua kelompok.




Gambar 4.4 Boxplot Distribusi Fitur Numerik vs Target

Boxplot diatas membandingkan median, kuartil (IQR), dan outlier dari enam fitur numerik antara kelompok Default=0 dan Default=1. Visualisasi ini melengkapi histogram dengan fokus pada ringkasan statistik distribusi.

- Age: Median usia nasabah default (~35 th) jauh lebih muda dari non-default (~45 th).
- Income: Median income nasabah default (~65 rb) lebih rendah dari non-default (~80 rb).

- c. LoanAmount: Median pinjaman nasabah default (~160 rb) lebih tinggi dari non-default (~130 rb).
- d. InterestRate: Median suku bunga default (~16%) lebih tinggi dari non-default (~13%).
- e. CreditScore & MonthsEmployed: Perbedaan median tidak terlalu menonjol.



Gambar 4.5 Heatmap Korelasi Antar Fitur

Heatmap menampilkan nilai korelasi Pearson antar semua fitur numerik dan variabel target Default. Warna cerah menunjukkan korelasi positif, warna gelap menunjukkan korelasi negatif atau mendekati nol.

- a. Korelasi dengan Default: Age (-0,17), Income (-0,09), MonthsEmployed (-0,10) berkorelasi negatif; InterestRate (+0,13) dan LoanAmount (+0,09) berkorelasi positif.
- b. Antar fitur: Seluruh korelasi antar fitur independen sangat rendah (mendekati 0) — tidak ada multikolinearitas yang serius.

4.2 EDA Spesifik Topik – Penanganan Data Tidak Seimbang

4.2.1 Analisis Ketidakseimbangan Kelas

Data dibagi menjadi data latih (80%) dan data uji (20%) menggunakan stratified split (random_state=42) untuk menjaga proporsi kelas. Data latih terdiri dari 24.000 sampel dengan rincian 21.234 kelas 0

dan 2.766 kelas 1 ($IR = 7,68 : 1$). Data uji terdiri dari 6.000 sampel dengan 5.309 kelas 0 dan 691 kelas 1, yang akan digunakan untuk evaluasi dalam kondisi distribusi asli (real-world).

4.2.2 Visualisasi Pola Ketidakseimbangan

Gambar 4.4 (sebagaimana telah disajikan) memperlihatkan dominasi kelas mayoritas secara visual. Dominasi ini dapat mengakibatkan model cenderung memprediksi semua sampel sebagai kelas mayoritas, yang akan menghasilkan akurasi tinggi tetapi recall kelas minoritas sangat rendah – fenomena yang dikenal sebagai accuracy paradox.

4.3 Implementasi Metode Resampling

Tiga metode hybrid resampling diterapkan hanya pada data latih:

1. SMOTE-ENN : Melakukan oversampling SMOTE diikuti cleaning dengan Edited Nearest Neighbours (ENN), yang menghapus sampel yang salah diklasifikasikan oleh k-nearest neighbor.
2. SMOTE-Tomek : Melakukan oversampling SMOTE diikuti pembersihan pasangan Tomek Links.
3. Borderline-SMOTE : Melakukan oversampling hanya pada sampel minoritas yang berada di area borderline (dekat kelas mayoritas), tanpa tahap cleaning.

Metode Resampling	Kelas 0	Kelas 1	Imbalance Ratio	Total Sample
Baseline (tanpa resampling)	21.234	2.766	7,68 : 1	24.000
SMOTE-ENN	11.636	21.075	0,55 : 1	32.711
SMOTE-Tomek	21.225	21.225	0,55 : 1	32.711
Borderline-SMOTE	21.234	21.234	1 : 1	42.468


Tabel 4.1. Perubahan distribusi kelas setelah masing-masing metode.

Penjelasan:


SMOTE-ENN dan SMOTE-Tomek menghasilkan distribusi di mana kelas minoritas menjadi lebih dominan karena proses *cleaning* yang agresif menghapus banyak sampel kelas mayoritas yang dianggap noise. Pada SMOTE-ENN, kelas 0 turun drastis dari 21.234 menjadi hanya 11.636 sampel, sementara SMOTE-Tomek mempertahankan kelas 0 di angka 21.225 karena mekanisme Tomek Links yang lebih selektif dalam menghapus hanya pasangan sampel paling ambigu di perbatasan keputusan. Meski demikian, keduanya menghasilkan total sampel dan rasio akhir yang identik (32.711 sampel, rasio 0,55 : 1), yang mengindikasikan bahwa perbedaan strategi *cleaning* tidak berdampak signifikan pada skala distribusi akhir dalam eksperimen ini. Berbeda dengan kedua metode tersebut, Borderline-SMOTE menghasilkan keseimbangan sempurna 1 : 1 tanpa mengurangi satu pun sampel mayoritas, kelas 0 tetap utuh di angka 21.234, sama persis dengan kondisi baseline dan hanya menambahkan sekitar 18.468 sampel sintetis secara terarah pada kelas minoritas di area perbatasan keputusan, sehingga menghasilkan total sampel terbesar di antara semua metode yang diuji, yakni 42.468 sampel.

4.4 Hasil Perbandingan Metode

Berikut hasil visualisasi dari perbandingan metode dan model yang sudah di uji didalam bahasa pemrograman python



Gambar 4.6 Precision-Recall Curve per Model



Gambar 4.7 Visual Evaluasi PR-AUC dan F1-SCORE

Gambar 4.6 menampilkan Precision-Recall Curve untuk ketiga model pada setiap skenario resampling, di mana baseline menghasilkan presisi awal tinggi namun recall sangat rendah, sementara penerapan resampling — terutama SMOTE-ENN — mendorong recall lebih tinggi dengan konsekuensi penurunan presisi. Hal ini diperkuat oleh Gambar 4.7 yang menyajikan perbandingan PR-AUC dan F1-Score dalam bentuk bar chart dan heatmap, menunjukkan bahwa

meskipun LightGBM + SMOTE-ENN mencapai F1-Score tertinggi (0,354), Logistic Regression + Borderline-SMOTE memberikan keseimbangan terbaik antara kedua metrik dengan F1-Score 0,338 dan PR-AUC 0,306, menjadikannya kombinasi paling optimal dalam penelitian ini.

4.4.1 Tabel Perbandingan Performa

Tiga algoritma klasifikasi, yaitu Random Forest (RF), LightGBM (LGBM), dan Logistic Regression (LR), dilatih pada setiap skenario resampling. Evaluasi dilakukan pada data uji asli (tanpa resampling) untuk memastikan performa model diukur pada distribusi data yang merepresentasikan kondisi nyata. Mengingat fokus penelitian adalah penanganan ketidakseimbangan kelas, evaluasi difokuskan pada kemampuan model dalam mendeteksi kelas minoritas (default), menggunakan metrik Precision, Recall, dan ROC-AUC untuk kelas 1 (default), serta PR-AUC (Precision-Recall Area Under Curve) dan F1-Score sebagai metrik utama.

1. Perbandingan Performa – Random Forest

Metode	Precision	Recall	F1-Score	ROC-AUC	PR-AUC
Baseline	0.64	0.01	0.03	0.716	0.284
SMOTE-ENN	0.25	0.49	0.33	0.725	0.246
SMOTE-Tomek	0.38	0.05	0.09	0.71	0.248
Borderline-SMOTE	0.39	0.07	0.12	0.717	0.249

Tabel 4.2. Perbandingan Performa – Random Forest

Berdasarkan hasil evaluasi pada mode Random Forest, terlihat bahwa metode resampling memberikan pengaruh yang berbeda terhadap kemampuan model dalam mendeteksi kelas minoritas (default). Pada

skenario baseline, model menghasilkan precision tertinggi (0,64), namun recall sangat rendah (0,01) dengan F1-score 0,03, yang menunjukkan bahwa model cenderung gagal mendeteksi sebagian besar kasus default. Di antara metode resampling, SMOTE-ENN menunjukkan performa terbaik dengan recall tertinggi (0,49) dan F1-score tertinggi (0,33), yang menandakan peningkatan kemampuan model dalam mengenali kelas minoritas, meskipun precision menurun menjadi 0,25. Sementara itu, SMOTE-Tomek dan Borderline-SMOTE hanya memberikan peningkatan terbatas dibanding baseline.

Nilai ROC-AUC relatif stabil pada seluruh skenario, yaitu sekitar 0,71–0,725, yang menunjukkan bahwa kemampuan pemisahan kelas secara umum tidak mengalami perubahan signifikan. Namun, karena penelitian ini berfokus pada penanganan ketidakseimbangan kelas, PR-AUC menjadi metrik yang lebih relevan. Dalam hal ini, baseline justru memiliki PR-AUC tertinggi (0,284) dibanding metode resampling (0,24), yang menunjukkan bahwa peningkatan kemampuan mendeteksi kelas minoritas belum selalu diikuti oleh peningkatan kualitas trade-off antara precision dan recall secara keseluruhan.

2. Perbandingan Performa – LightGBM

Metode	Precision	Recall	F1-Score	ROC-AUC	PR-AUC
Baseline	0.53	0.07	0.12	0.735	0.296
SMOTE-ENN	0.28	0.50	0.35	0.736	0.286
SMOTE-Tomek	0.54	0.08	0.14	0.738	0.297
Borderline-SMOTE	0.48	0.08	0.14	0.737	0.294

Tabel 4.3. Perbandingan Performa – LightGBM

Berdasarkan hasil evaluasi pada model LightGBM, metode resampling menunjukkan pengaruh yang berbeda terhadap kemampuan deteksi kelas minoritas (default). Pada skenario baseline, model

menghasilkan precision sebesar 0,53, namun recall hanya 0,07 dengan F1-score 0,12, yang menunjukkan bahwa model masih cenderung kurang efektif dalam menangkap kasus default. Di antara seluruh metode resampling, SMOTE-ENN kembali menunjukkan performa terbaik dengan recall tertinggi (0,50) dan F1-score tertinggi (0,35), yang mengindikasikan peningkatan kemampuan model dalam mendeteksi kelas minoritas. Namun, peningkatan tersebut disertai penurunan precision menjadi 0,28, yang menunjukkan adanya peningkatan false positive. Sementara itu, SMOTE-Tomek dan Borderline-SMOTE hanya memberikan peningkatan yang sangat terbatas dibanding baseline.

Nilai ROC-AUC pada seluruh skenario relatif stabil, yaitu di kisaran 0,735–0,738, yang menunjukkan bahwa kemampuan model dalam memisahkan kedua kelas secara umum tidak mengalami perubahan signifikan akibat penerapan resampling. Dari sisi PR-AUC, perbedaan performa juga relatif kecil, dengan SMOTE-Tomek menghasilkan nilai tertinggi (0,297), sedikit di atas baseline (0,296) dan Borderline-SMOTE (0,294), sedangkan SMOTE-ENN memiliki nilai terendah (0,286). Hal ini menunjukkan bahwa meskipun SMOTE-ENN secara signifikan meningkatkan recall, peningkatan tersebut belum sepenuhnya menghasilkan trade-off yang optimal antara precision dan recall secara keseluruhan.

3. Perbandingan Performa - Logistic Regression

Metode	Precision	Recall	F1-Score	ROC-AUC	PR-AUC
Baseline	0.61	0.04	0.08	0.751	0.310
SMOTE-ENN	0.17	0.87	0.29	0.748	0.303
SMOTE-Tomek	0.22	0.69	0.34	0.748	0.304
Borderline-SMOTE	0.23	0.65	0.34	0.750	0.306

Tabel 4.4 Perbandingan Performa - Logistic Regression

Berdasarkan hasil evaluasi pada model Logistic Regression, penerapan metode resampling memberikan dampak yang jauh lebih signifikan terhadap kemampuan deteksi kelas minoritas (default) dibandingkan skenario baseline. Pada kondisi baseline, model menghasilkan precision tertinggi (0,61), namun recall sangat rendah (0,04) dengan F1-score hanya 0,08, yang menunjukkan bahwa model hampir tidak mampu mendeteksi kasus default. Setelah penerapan resampling, performa recall meningkat secara drastis. SMOTE-ENN menghasilkan recall tertinggi (0,87), namun precision turun menjadi 0,17, yang menunjukkan meningkatnya prediksi false positive. Sementara itu, SMOTE-Tomek dan Borderline-SMOTE memberikan keseimbangan yang lebih baik, dengan F1-score tertinggi sebesar 0,34, menunjukkan kompromi yang lebih optimal antara precision dan recall.

Nilai ROC-AUC relatif stabil pada seluruh skenario, yaitu di kisaran 0,748–0,751, yang menunjukkan bahwa kemampuan pemisahan kelas secara umum tidak mengalami perubahan signifikan akibat penerapan resampling. Dari sisi PR-AUC, perbedaan performa juga relatif kecil, dengan baseline menghasilkan nilai tertinggi (0,31), diikuti Borderline-SMOTE (0,306), SMOTE-Tomek (0,304), dan SMOTE-ENN (0,303). Hal ini menunjukkan bahwa meskipun resampling secara signifikan meningkatkan kemampuan model dalam menangkap kelas minoritas, peningkatan tersebut belum sepenuhnya menghasilkan peningkatan kualitas trade-off antara precision dan recall secara keseluruhan.

4.5 Pembahasan

4.5.1 Analisis Metode Terbaik

Berdasarkan hasil perbandingan performa menggunakan dua metrik utama, yaitu F1-score dan PR-AUC (Precision-Recall Area Under Curve), kombinasi Logistic Regression dengan Borderline-SMOTE menunjukkan performa yang paling seimbang di antara seluruh skenario yang diuji. Kombinasi ini menghasilkan F1-score sebesar 0,34 dan

PR-AUC sebesar 0,306, yang menunjukkan keseimbangan yang baik antara kemampuan model dalam mendeteksi kelas minoritas (default) dan kualitas performa model secara keseluruhan pada berbagai nilai threshold. Dalam konteks data tidak seimbang, kedua metrik ini dinilai lebih representatif dibandingkan accuracy atau ROC-AUC, karena secara langsung mengevaluasi performa model terhadap kelas minoritas yang menjadi fokus penelitian.

Meskipun LightGBM dengan SMOTE-ENN menghasilkan F1-score tertinggi sebesar 0,35, nilai PR-AUC yang lebih rendah (0,287) menunjukkan bahwa performa model belum seoptimal Logistic Regression + Borderline-SMOTE apabila konsistensi performa pada berbagai threshold turut dipertimbangkan. Sebaliknya, Logistic Regression baseline menghasilkan PR-AUC tertinggi sebesar 0,310, namun F1-score yang sangat rendah (0,08) menunjukkan bahwa model kurang efektif dalam mendeteksi kasus default, sehingga belum dapat dianggap sebagai solusi optimal dalam konteks penelitian ini.

Berdasarkan pertimbangan tersebut, kombinasi Logistic Regression + Borderline-SMOTE dipilih sebagai kandidat model terbaik untuk tahap cross-validation dan hyperparameter tuning. Pemilihan ini tidak didasarkan pada pencapaian nilai tertinggi pada satu metrik tertentu, melainkan pada kemampuannya memberikan performa yang paling seimbang sesuai dengan tujuan penelitian, yaitu meningkatkan kemampuan deteksi kelas minoritas tanpa mengorbankan kualitas klasifikasi secara keseluruhan.

4.5.2 Trade-off Precision vs Recall

Hasil evaluasi menunjukkan adanya trade-off yang jelas antara precision dan recall pada berbagai skenario resampling. Pada model baseline tanpa resampling, nilai precision cenderung lebih tinggi, namun recall sangat rendah. Sebagai contoh, Logistic Regression baseline menghasilkan precision sebesar 0,61, tetapi recall hanya 0,04, yang menunjukkan bahwa model sangat konservatif dalam memberikan prediksi

default. Kondisi ini menyebabkan sebagian besar kasus default gagal terdeteksi, meskipun prediksi positif yang dihasilkan relatif lebih akurat.

Sebaliknya, penerapan metode resampling secara umum meningkatkan kemampuan model dalam mendeteksi kelas minoritas, yang ditunjukkan oleh kenaikan nilai recall. Pada kombinasi Logistic Regression dengan SMOTE-ENN, recall meningkat drastis menjadi 0,87, namun precision turun menjadi 0,17, yang menunjukkan peningkatan jumlah false positive. Fenomena ini menunjukkan bahwa model menjadi jauh lebih agresif dalam mengidentifikasi potensi default, tetapi dengan konsekuensi meningkatnya prediksi positif yang keliru.

Kombinasi Logistic Regression dengan Borderline-SMOTE menunjukkan kompromi yang lebih seimbang, dengan precision sebesar 0,23 dan recall sebesar 0,65, sehingga menghasilkan F1-score yang lebih stabil dibanding pendekatan yang terlalu konservatif maupun terlalu agresif. Temuan ini menunjukkan bahwa dalam konteks prediksi loan default, peningkatan recall memang penting untuk meminimalkan kegagalan mendeteksi debitur berisiko, namun precision tetap perlu dipertimbangkan agar model tidak menghasilkan terlalu banyak alarm palsu. Oleh karena itu, keseimbangan antara kedua metrik menjadi faktor penting dalam pemilihan model terbaik.

4.5.3 Perbandingan dengan Baseline

Perbandingan dengan skenario baseline menunjukkan bahwa penerapan metode resampling memberikan peningkatan yang signifikan terhadap kemampuan model dalam mendeteksi kelas minoritas (default). Pada kondisi baseline, seluruh algoritma cenderung menghasilkan precision yang relatif tinggi, namun recall sangat rendah, yang menunjukkan bahwa model lebih banyak memprediksi kelas mayoritas dan gagal mengenali sebagian besar kasus default. Sebagai contoh, Random Forest, LightGBM, dan Logistic Regression pada baseline masing-masing hanya menghasilkan recall sebesar 0,01; 0,07; dan 0,04,

yang mengindikasikan kemampuan deteksi kelas minoritas yang sangat terbatas.

Setelah penerapan metode resampling, peningkatan performa terlihat jelas terutama pada metrik recall dan F1-score. Random Forest dengan SMOTE-ENN meningkatkan F1-score dari 0,03 menjadi 0,33, LightGBM dengan SMOTE-ENN dari 0,12 menjadi 0,35, dan Logistic Regression dengan Borderline-SMOTE dari 0,08 menjadi 0,34. Temuan ini menunjukkan bahwa model yang dilatih dengan penanganan ketidakseimbangan kelas mampu mempelajari pola kelas minoritas dengan jauh lebih baik dibanding baseline, sehingga penerapan teknik resampling menjadi langkah penting dalam meningkatkan efektivitas prediksi loan default.

4.5.4 Kinerja Antar Algoritma

Berdasarkan hasil evaluasi, ketiga algoritma menunjukkan karakteristik performa yang berbeda dalam menangani data tidak seimbang. Random Forest cenderung lebih konservatif, dengan performa baseline yang sangat rendah dalam mendeteksi kelas minoritas, namun menunjukkan peningkatan yang cukup signifikan setelah penerapan resampling, khususnya dengan SMOTE-ENN. LightGBM menunjukkan performa yang lebih stabil dengan nilai F1-score tertinggi sebesar 0,35 pada kombinasi SMOTE-ENN, yang menunjukkan kemampuan klasifikasi yang baik dalam menyeimbangkan precision dan recall. Sementara itu, Logistic Regression menunjukkan respons paling kuat terhadap penerapan resampling, terutama dalam peningkatan kemampuan mendeteksi kelas minoritas.

Pada model Logistic Regression, metode resampling mampu meningkatkan recall secara signifikan dibanding baseline, dengan kombinasi Borderline-SMOTE menghasilkan performa yang paling seimbang berdasarkan metrik utama penelitian. Temuan ini menunjukkan bahwa meskipun algoritma berbasis ensemble seperti Random Forest dan LightGBM memiliki performa yang baik, Logistic Regression justru lebih

adaptif terhadap penanganan ketidakseimbangan kelas pada dataset ini. Hal ini mengindikasikan bahwa efektivitas algoritma tidak hanya ditentukan oleh kompleksitas model, tetapi juga oleh kesesuaian karakteristik model terhadap distribusi data dan strategi resampling yang digunakan.

4.6 Ringkasan Temuan

Berdasarkan seluruh rangkaian eksperimen, beberapa temuan utama dapat disimpulkan sebagai berikut :

1. Dataset Loan Default Prediction menunjukkan bahwa kondisi ketidakseimbangan kelas yang signifikan, dengan rasio kelas mayoritas terhadap kelas minoritas sekitar 7,68:1, sehingga model baseline cenderung bias terhadap kelas mayoritas dan memiliki kemampuan yang rendah dalam mendeteksi kasus default.
2. Penerapan teknik resampling terbukti meningkatkan kemampuan model dalam mendeteksi kelas minoritas, khususnya pada metrik recall dan F1-score, dibandingkan model baseline yang dilatih pada distribusi data asli tanpa penanganan ketidakseimbangan kelas.
3. Logistic Regression dengan Borderline-SMOTE menunjukkan performa paling seimbang pada tahap perbandingan awal, dengan F1-score sebesar 0,34 dan PR-AUC sebesar 0,306, sehingga dipilih sebagai kandidat model terbaik untuk tahap evaluasi lanjutan.
4. LightGBM dengan SMOTE-ENN menghasilkan F1-score tertinggi (0,35), namun nilai PR-AUC yang lebih rendah (0,287) menunjukkan bahwa performanya kurang konsisten pada berbagai nilai threshold dibanding kandidat terpilih.
5. Hasil cross-validation menunjukkan performa model yang relatif stabil, ditandai dengan nilai deviasi standar yang kecil pada metrik evaluasi, sehingga menunjukkan bahwa kandidat model memiliki konsistensi performa yang baik pada berbagai subset data latih.
6. Proses hyperparameter tuning pada Logistic Regression tidak menghasilkan peningkatan performa yang signifikan dibandingkan

konfigurasi awal, yang menunjukkan bahwa konfigurasi model awal telah berada pada kondisi yang relatif sesuai untuk dataset yang digunakan.

7. Secara keseluruhan, strategi penanganan ketidakseimbangan kelas memberikan pengaruh yang lebih besar terhadap peningkatan performa model dibandingkan optimasi hyperparameter, khususnya dalam konteks prediksi loan default dengan distribusi data yang tidak seimbang.

BAB V

Kesimpulan dan Saran

5.1 Kesimpulan

Penelitian ini membandingkan dua belas eksperimen persilangan antara dua teknik hybrid resampling (SMOTE-ENN dan SMOTE-Tomek) dan satu teknik oversampling (Borderline-SMOTE), beserta satu skenario baseline (tanpa resampling) terhadap tiga algoritma klasifikasi (Random Forest, LightGBM, dan Logistic Regression) dalam menangani class imbalance pada dataset Loan Default Prediction dengan mengutamakan evaluasi yang berfokus pada metrik F1-Score dan PR-AUC.

Berdasarkan hasil dari eksperimen, ditemukan bahwa penerapan teknik resampling secara konsisten meningkatkan kemampuan model dalam mendeteksi nasabah *default* dibandingkan dengan baseline. Tanpa melakukan resampling, seluruh algoritma yang digunakan tidak mampu untuk mendeteksi kelas minoritas, yang bisa kita lihat pada *Recall* setiap algoritma yang sangat rendah dengan Random Forest dengan nilai *Recall* 0,01, LightGBM bernilai 0,07, dan Logistic Regression bernilai 0,04. Hal ini membuktikan bahwa model yang dilatih pada data *imbalanced* tanpa ada penanganan secara khusus akan berdampak pada hasil akhir model yang menjadi bias terhadap kelas mayoritas, meskipun secara akurasi global hasilnya tampak tinggi.

Di antara seluruh metode resampling, SMOTE-ENN yang paling agresif dalam mendorong *Recall*, namun dengan imbas proses cleaning secara dua arah yang memangkas sampel kelas mayoritas dari 21.234 menjadi 11.636 sampel, pemangkasan ini berdampak pada penurunan *Precision* yang tajam. Borderline-SMOTE menghasilkan sampel yang lebih seimbang karena hanya menambah sampel sintetis di area *borderline* tanpa menyentuh distribusi sampel kelas mayoritas, yang dimana *trade-off Precision-Recall* yang dihasilkan lebih terkendali. Sedangkan SMOTE-Tomek memiliki hasil yang moderat karena berada di antara SMOTE-ENN dengan Borderline-SMOTE.

Dari segi penerapan algoritma, Logistic Regression menunjukkan responsivitas yang lebih tinggi terhadap resampling, mengingat bahwa kompleksitas dari algoritma ini lebih rendah dibandingkan dengan Random Forest maupun LightGBM. Kombinasi antara Logistic Regression dengan Borderline-SMOTE menunjukkan bahwa kombinasi yang terbaik dengan F1-Score 0,34 dan PR-AUC 0,306. Hasil ini menunjukkan keunggulan kombinasi ini dalam konsistensi performa lintas *threshold* dibandingkan dengan kombinasi antara LightGBM dengan SMOTE-ENN yang meraih F1-Score 0,35 tetapi dengan PR-AUC yang lebih rendah di angka 0,286. Temuan ini membuktikan bahwa dalam konteks *imbalanced data* kompleksitas model bukanlah penentu performa secara mutlak, melainkan kesesuaian antara karakteristik model dan strategi resampling justru yang lebih krusial.

5.2 Keterbatasan Penelitian

Penelitian ini memiliki beberapa keterbatasan yang perlu dipertimbangkan dalam interpretasi hasil:

1. Sampel dataset yang digunakan hanya 30.000 sampel dari 255.347 baris hasil, sehingga generalisasi pada temuan ke skala populasi penuh perlu diujikan lebih lanjut.
2. *Feature Engineering* tidak diberlakukan dalam membatasi eksplorasi potensi fitur turunan yang relevan seperti *Loan-to-income Ratio* atau interaksi fitur keuangan.
3. Nilai *default* digunakan seluruhnya sebagai parameter resampling, tanpa eksplorasi konfigurasi *k-neighbor* atau rasio *sampling* alternatif untuk kemungkinan hasil distribusi data latih yang lebih optimal.
4. *Hyperparameter* hanya dilakukan pada salah satu kombinasi yang terbaik, sehingga belum menggambarkan potensi maksimal dari kombinasi yang lain.

5.3 Saran

Untuk penelitian selanjutnya kami menyarankan:

1. Menguji metode resampling yang adaptif seperti ADASYN yang dapat menyesuaikan densitas sintetis berdasarkan tingkat kesulitan klasifikasi tiap sampel, sebagai pembandingan terhadap metode yang telah digunakan dalam penelitian ini.
2. Mengeksplorasi *feature engineering* untuk basis domain keuangan, seperti rasio pinjaman terhadap pendapatan dan interaksi antara *CreditScore* dengan *DTIRatio*, agar dapat meningkatkan daya pisah model di area *borderline* antar kelas.
3. Memperluas *hyperparameter tuning* untuk seluruh kombinasi model agar dapat ditemukan perbandingan yang lebih adil dan komprehensif.
4. Melakukan eksperimen dengan menggunakan dataset penuh (255.347 baris) untuk membuktikan konsistensi dari setiap temuan model pada data dengan skala yang lebih representatif.

DAFTAR PUSTAKA

- Adewumi, A. A., Akande, N. O., Usman, F. E., Adebayo, O. A., & Ajala, O. A. (2025, April). An improved ensemble method with data resampling for credit risk prediction. *IEEE Access*, *13*, 71275-71287.
10.1109/ACCESS.2025.0000001
- Akinjole, A., Shobayo, O., Popoola, J., Okoyeigbo, O., & Ogunleye, B. (2024, October). Ensemble-Based Machine Learning Algorithm for Loan Default Risk Prediction. *I2(3423)*, 31. <https://doi.org/10.3390/math12213423>
- ALTALHAN, M., ALGARNI, A., & ALOUANE, M. T.-H. (2025, january 20). Imbalanced Data problem in Machine Learning: A review. 14.
10.1109/ACCESS.2025.3531662
- Baloch, S., & Muhammad, M. S. (2021, February 2). An Intelligent Data Mining-Based Fault Detection and Classification Strategy for Microgrid. 22470 - 22479. 10.1109/ACCESS.2021.3056534
- Deshpande, H. S., & Ragha, L. (2025, September). An empirical examination of classification algorithms and resampling strategies for dealing with imbalanced datasets: a comparative analysis. *International Journal of Data Analysis Techniques and Strategies*, *17(3)*.
<https://doi.org/10.1504/IJDATS.2025.148563>
- Dong, H., Liu, R., & Tham, A. W. (2024, January). Accuracy Comparison between Five Machine Learning Algorithms for Financial Risk Evaluation. *I7(50)*, 19. <https://doi.org/10.3390/jrfm17020050>
- Karabacak, E. S., & Yaslan, Y. (2023, October 24). Comparison of Machine Learning Methods for Early Detection of Student Dropouts.
10.1109/UBMK59864.2023.10286747
- Khleel, N. (2022, november). A Novel Approach for Software Defect Prediction using CNN and GRU Based on SMOTE Tomek Method. *Research Square*.
doi.org/10.21203/rs.3.rs-2305042/v2
- Masruriyah, A. F. N., Novita, H. Y., Sukmawati, C. E., Fauzi, A., Wahiddin, D., & Handayani, H. H. (2024). Thorough Evaluation of the Effectiveness of SMOTE and ADASYN Oversampling Methods in Enhancing Supervised

- Learning Performance for Imbalanced Heart Disease Datasets. *Thorough Evaluation of the Effectiveness of SMOTE and ADASYN Oversampling Methods in Enhancing Supervised Learning Performance for Imbalanced Heart Disease Datasets*, 1(1), 12. 10.1109/ICIC60109.2023.10382105
- Mujahid, M., Kina, E., Rustam, F., Villar, M. G., Alvarado, E. S., Diez, I. D. L. T., & Ashraf, I. (2024, june). Journal of Big Data. *Data oversampling and imbalanced datasets: an investigation of performance for machine learning and feature engineering*, 11. doi.org/10.1186/s40537-024-00943-4
- Mukherjee, A., Qazani, M. R. C., Rana, B.M. J., Akter, S., Mohajerzadeh, A., Sathi, N. J., Ali, L. E., Khan, M. S., & Asadi, H. (2025, September). SMOTE-ENN resampling technique with Bayesian optimization for multi-class classification of dry bean varieties. *Applied Soft Computing*, 181(113467), 18. https://doi.org/10.1016/j.asoc.2025.113467
- Sharma, A., Dhanka, S., Sharma, A., Maini, S., Fahlevi, M., Rabby, F., Aljuaid, M., & Bansal, R. (2025). Accuracy, precision, recall, f1-score, or MCC? empirical evidence from advanced statistics, ML, and XAI for evaluating business predictive models. *Journal of Big Data*, 12, 268. 10.1186/s40537-025-01313-4
- Shreya, & Pathak, H. (2025, Jun). Explainable Artificial Intelligence Credit Risk Assessment using Machine Learning. *arXiv:2506.19383*, 15. https://doi.org/10.48550/arXiv.2506.19383
- Sirait, J. B., Togatorop, P. R., Tambunan, P. M.L.P., Marpaung, Y. F. Y., Situmeang, S. I.G., & Simanjuntak, H. T.A. (2023, September 8). Predicting Students Performance Using Data Mining Approach (Case Study: IT Del). 10.1109/ICoDSE59534.2023.10291748
- Sun, Y., Que, H., Cai, Q., Zhao, J., Li, J., Kong, Z., & Wang, S. (2022, Juni 24). Borderline SMOTE Algorithm and Feature Selection-Based Network Anomalies Detection Strategy. *mdpi.com/1996-1073/15/13/4751*. https://doi.org/10.3390/en15134751
- Ying, C., Shi, A., & Li, X. (2025, July). Hybrid boosted attention-based LightGBM framework for enhanced credit risk assessment in digital

finance. *Humanities and Social Sciences Communications*, 13.
<https://doi.org/10.1057/s41599-025-05230-y>

Yu, C., Jin, Y., Xing, Q., Zhang, Y., Guo, S., & Meng, S. (2024, Nov). Advanced User Credit Risk Prediction Model using LightGBM, XGBoost and Tabnet with SMOTEENN. 7. <https://arxiv.org/abs/2408.03497>

Zhang, Y., Deng, L., & Wei, B. (2024, Mei 30). Imbalanced Data Classification Based on Improved Random-SMOTE and Feature Standard Deviation. <https://doi.org/10.3390/math12111709>

LAMPIRAN

Link Repository Github :

<https://github.com/PrimaSembiring/loan-default-imbalance.git>